

# Deep Learning - Cats & Dogs Classification

January 10, 2021

## 1 Práctica 4

### 1.1 Clasificación de imágenes de perros y gatos empleando técnicas de Deep Learning

#### 1.1.1 Introducción

El objetivo de esta práctica es establecer un primer contacto con el mundo de las redes neuronales y el Deep Learning, en concreto en el ámbito de la Visión por Computador. Para tal fin se propone construir una red neuronal capaz de clasificar imágenes de perros y gatos.

Para la realización de la práctica se empleará la API Keras de TensorFlow, una herramienta muy utilizada actualmente. Además se va a hacer uso de la plataforma Google Colaboratory, que permite, entre otras cosas, hacer uso gratuito de potentes GPU en servidores remotos. Así pues, esta práctica también sirve como una primera toma de contacto con estas conocidas y útiles herramientas.

#### 1.1.2 Datos

En esta práctica se hará uso de un dataset que contiene un total de 3000 imágenes de perros y gatos de diferentes tamaños. Este dataset ya se proporciona con la organización de directorios apropiada para este ejercicio:

- Cat\_dog\_filtered -> directorio padre
- Train -> conjunto de entrenamiento
  - Cats -> Clase de gatos
  - Dogs -> Clase de perros
- Validation -> Conjunto de validación
  - Cats -> Clase de gatos
  - Dogs -> Clase de perros

**Data augmentation** La técnica del *data augmentation* permite aumentar el conjunto de datos de datos original. En particular, permite crear nuevas imágenes aplicando transformaciones geométricas sobre las existentes, generando así nuevas imágenes realistas para entrenar el modelo. Esta técnica nos permite evitar el *overfitting* del modelo cuando no se dispone de un conjunto muy grande de datos, lo cual puede derivar en el modelado del ruido presente en estos.

### 1.2 Comienzo de la práctica

Primero de todo se importan todas aquellas librerías necesarias para el desarrollo de la práctica. De Keras, nos interesa la librería *layers*, la cual permite instanciar objetos a modo de diferentes capas

de la red neuronal, y *Sequential*, que será el modelo a emplear en esta práctica. Este modelo es apropiado cuando se busca una red construida por una secuencia de capas, donde cada una recibe con entrada un solo tensor y tiene como salida otro tensor.

```
[ ]: import tensorflow as tf
import matplotlib.pyplot as plt

from tensorflow import keras
from tensorflow.keras import layers
from tensorflow.keras.models import Sequential
```

A continuación confirmamos que nos podemos conectar a una GPU con TensorFlow.

```
[ ]: device_name = tf.test.gpu_device_name()
if device_name != '/device:GPU:0':
    raise SystemError('GPU device not found')
print('Found GPU at: {}'.format(device_name))
```

Found GPU at: /device:GPU:0

Bien, parece que existe una conexión.

Se definen algunos parámetros importantes para el desarrollo de la práctica:

- *Batch size* : tamaño del *batch* de imágenes que se leerá cada vez del disco.
- *img\_height* y *img\_width* : tamaño de la imagen leída. Si una imagen del conjunto no coincide con este tamaño, se transforma a dichas dimensiones.

```
[ ]: batch_size = 25 #adecuado para el problema
img_height = 256
img_width = 256
```

**Data augmentation** A continuación se crean los objetos que van a permitir coger *batches* de imágenes desde disco y generar artificialmente nuevas en tiempo real. Este objeto es el *ImageDataGenerator* de Keras. En su constructor, permite definir una serie de parámetros a utilizar en la generación de imágenes, como el ángulo máximo de rotación (*rotation range*) o la fracción total de zoom (*zoom range*).

Se definen así los generadores de imágenes para el conjunto de entrenamiento (*train\_datagen*) y validación (*val\_datagen*).

```
[ ]: train_datagen = tf.keras.preprocessing.image.ImageDataGenerator(
    featurewise_center = True,
    featurewise_std_normalization = True,
    rotation_range = 90,
    width_shift_range = 0.1,
    height_shift_range = 0.1,
    zoom_range = 0.2
)
```

```

val_datagen = tf.keras.preprocessing.image.ImageDataGenerator(
    featurewise_center = True,
    featurewise_std_normalization = True,
    rotation_range = 90,
    width_shift_range = 0.1,
    height_shift_range = 0.1,
    zoom_range = 0.2
)

```

Se definen los directorios donde residen las imágenes buscadas. El argumento *class mode* permite etiquetar automáticamente de forma binaria las imágenes pertenecientes a las dos clases: perros y gatos divididos en directorios separados. Esta información se almacena en el objeto *train\_generator* y *validation\_generator*, que se emplearán posteriormente cuando se entrene el modelo. Serán los encargados de leer imágenes de disco y aplicar en tiempo real el *data augmentation*.

Una gran ventaja de emplear estos generadores en la práctica es que no es necesario que el conjunto entero de datos quepa en memoria RAM, lo cual es poco realista en la mayoría de problemas. Esto es así ya que durante el entrenamiento del modelo se van cargando *batches* de tamaño reducido desde disco y no se carga el dataset entero. Cada *batch* se emplea para realizar un paso en el descenso del gradiente. Cuando se ha completado, se carga otro *batch* y se realiza lo mismo.

```

[ ]: train_generator = train_datagen.flow_from_directory('./drive/MyDrive/DP_Vision/
    ↪in/cat_and_dog_filtered/train',
                                                    target_size =_
    ↪(img_height,img_width),
                                                    batch_size = batch_size,
                                                    class_mode = 'binary')

validation_generator = val_datagen.flow_from_directory('./drive/MyDrive/
    ↪DP_Vision/in/cat_and_dog_filtered/validation',
                                                    target_size =_
    ↪(img_height,img_width),
                                                    batch_size = batch_size,
                                                    class_mode = 'binary')

```

```

Found 2000 images belonging to 2 classes.
Found 1000 images belonging to 2 classes.

```

Por salida estándar se nos muestra el número de imágenes de entrenamiento y validación encontradas y el número de clases total en ambos grupos. En este caso 2 clases, perros y gatos.

**Modelo 1** Se define la arquitectura del primer modelo. Lo primero de todo es la capa de entrada, en la cual definimos el tamaño de las imágenes. En este caso, al ser imágenes RGB se debe poner un 3 en la tercera dimensión (número de canales). Posteriormente se alternan capas de convolución y capas de *max pooling*. Las capas de *max pooling* ayudan a reducir la dimensionalidad de las capas de convolución extrayendo el valor máximo de cada paso del filtro por la imagen. Además permiten cada vez más identificar características de más alto nivel a medida que se hace más profunda la red. Finalmente se aplanan a una sola dimensión el resultado de las capas de convolución, de tal

manera que se dispone la información en el formato adecuado para introducirlo en un perceptrón multicapa. Este estará compuesto por una capa oculta de 128 neuronas y una capa de salida que emplea la función *softmax* para generar una salida con valores entre 0 y 1, tal que la suma de las salidas sea 1. Así se consigue una distribución de probabilidad de la pertenencia de una observación (imagen) a cada clase.

La diferencia entre este modelo y el siguiente es la función de activación y de coste, como se verá más adelante.

```
[ ]: model = Sequential([
    layers.InputLayer(input_shape=(img_height,img_width,3)),
    layers.Conv2D(10, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Conv2D(20, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Conv2D(40, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Flatten(),
    layers.Dense(128, activation='relu'),
    layers.Dense(2,activation='softmax') # 2 classes
])
```

A continuación se definen la función de pérdida a optimizar, así como la métrica a evaluar durante el entrenamiento. Como función de pérdida se escoge la *sparse categorical cross entropy*, que según la documentación oficial, es válida únicamente cuando se disponen de dos o más salidas en forma de distribución de probabilidad. La métrica escogida es el *accuracy*.

También se podría seleccionar el método de optimización de la función de coste. En este caso se escoge el de por defecto, el algoritmo RMSprop.

```
[ ]: model.compile(#optimizer='adam',
                   loss=tf.keras.losses.SparseCategoricalCrossentropy(),
                   metrics=['accuracy'])
```

La función *summary* nos permite ver de forma esquemática la arquitectura de la red creada.

```
[ ]: model.summary()
```

Model: "sequential\_10"

Layer (type)	Output Shape	Param #
conv2d_30 (Conv2D)	(None, 256, 256, 10)	280
max_pooling2d_30 (MaxPooling)	(None, 128, 128, 10)	0
conv2d_31 (Conv2D)	(None, 128, 128, 20)	1820
max_pooling2d_31 (MaxPooling)	(None, 64, 64, 20)	0

conv2d_32 (Conv2D)	(None, 64, 64, 40)	7240
-----		
max_pooling2d_32 (MaxPooling)	(None, 32, 32, 40)	0
-----		
flatten_10 (Flatten)	(None, 40960)	0
-----		
dense_20 (Dense)	(None, 128)	5243008
-----		
dense_21 (Dense)	(None, 2)	258
=====		
Total params: 5,252,606		
Trainable params: 5,252,606		
Non-trainable params: 0		

Finalmente se procede a entrenar el modelo. Se hace uso de la función *fit\_generator*, que nos permite entrenar el modelo haciendo uso de los generadores creados tanto para el conjunto de entrenamiento como validación. El argumento *steps\_per\_epoch* permite establecer el número de pasos de descenso del gradiente a realizar por *epoch*. Es decir, el número de *batches* por *epoch*. En este caso, para asegurar que no se excede el número de imágenes disponibles (lo cual ha sucedido), este argumento se inicializa al número de *batches* máximo que encaja con las imágenes que se tienen.

En un principio el número de *batches* se inicializó a 32 y los pasos por *epoch* a 100, lo cual supone un total de 3200 imágenes. Esto hacía saltar un error que daba entender que se paraba el entrenamiento por insuficiencia de *inputs*. Así que se modificó a los valores actuales.

```
[ ]: history = model.fit_generator (
    train_generator,
    steps_per_epoch = 2000/batch_size,
    epochs = 100,
    validation_data = validation_generator,
    validation_steps=1000/batch_size
)
```

```
/usr/local/lib/python3.6/dist-
packages/tensorflow/python/keras/engine/training.py:1844: UserWarning:
`Model.fit_generator` is deprecated and will be removed in a future version.
Please use `Model.fit`, which supports generators.
  warnings.warn("`Model.fit_generator` is deprecated and '
/usr/local/lib/python3.6/dist-
packages/keras_preprocessing/image/image_data_generator.py:720: UserWarning:
This ImageDataGenerator specifies `featurewise_center`, but it hasn't been fit
on any training data. Fit it first by calling `.fit(numpy_data)`.
  warnings.warn('This ImageDataGenerator specifies '
/usr/local/lib/python3.6/dist-
packages/keras_preprocessing/image/image_data_generator.py:728: UserWarning:
This ImageDataGenerator specifies `featurewise_std_normalization`, but it hasn't
been fit on any training data. Fit it first by calling `.fit(numpy_data)`.
  warnings.warn('This ImageDataGenerator specifies '
```

Epoch 1/100  
80/80 [=====] - 48s 595ms/step - loss: 212.7686 - accuracy: 0.5028 - val\_loss: 0.6928 - val\_accuracy: 0.5810

Epoch 2/100  
80/80 [=====] - 46s 581ms/step - loss: 0.7317 - accuracy: 0.5615 - val\_loss: 0.6864 - val\_accuracy: 0.5650

Epoch 3/100  
80/80 [=====] - 46s 578ms/step - loss: 0.7147 - accuracy: 0.5540 - val\_loss: 0.6876 - val\_accuracy: 0.5700

Epoch 4/100  
80/80 [=====] - 46s 576ms/step - loss: 0.7021 - accuracy: 0.5568 - val\_loss: 0.7001 - val\_accuracy: 0.5390

Epoch 5/100  
80/80 [=====] - 46s 577ms/step - loss: 0.7108 - accuracy: 0.5722 - val\_loss: 0.6642 - val\_accuracy: 0.5850

Epoch 6/100  
80/80 [=====] - 46s 575ms/step - loss: 0.7028 - accuracy: 0.5855 - val\_loss: 0.6917 - val\_accuracy: 0.5580

Epoch 7/100  
80/80 [=====] - 46s 581ms/step - loss: 0.7110 - accuracy: 0.5877 - val\_loss: 0.6974 - val\_accuracy: 0.5460

Epoch 8/100  
80/80 [=====] - 46s 574ms/step - loss: 0.7199 - accuracy: 0.5687 - val\_loss: 0.6660 - val\_accuracy: 0.6060

Epoch 9/100  
80/80 [=====] - 47s 587ms/step - loss: 0.6781 - accuracy: 0.6226 - val\_loss: 0.6496 - val\_accuracy: 0.6220

Epoch 10/100  
80/80 [=====] - 46s 582ms/step - loss: 0.6647 - accuracy: 0.6153 - val\_loss: 0.7086 - val\_accuracy: 0.5610

Epoch 11/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6771 - accuracy: 0.6277 - val\_loss: 0.6916 - val\_accuracy: 0.5810

Epoch 12/100  
80/80 [=====] - 46s 578ms/step - loss: 0.6851 - accuracy: 0.6200 - val\_loss: 0.7295 - val\_accuracy: 0.6250

Epoch 13/100  
80/80 [=====] - 46s 578ms/step - loss: 0.6480 - accuracy: 0.6394 - val\_loss: 0.6433 - val\_accuracy: 0.6200

Epoch 14/100  
80/80 [=====] - 46s 583ms/step - loss: 0.6657 - accuracy: 0.6390 - val\_loss: 0.7583 - val\_accuracy: 0.5680

Epoch 15/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6575 - accuracy: 0.6286 - val\_loss: 0.6312 - val\_accuracy: 0.6630

Epoch 16/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6471 - accuracy: 0.6305 - val\_loss: 0.6188 - val\_accuracy: 0.6550

Epoch 17/100  
80/80 [=====] - 46s 574ms/step - loss: 0.6441 - accuracy: 0.6587 - val\_loss: 0.6045 - val\_accuracy: 0.6880  
Epoch 18/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6311 - accuracy: 0.6675 - val\_loss: 0.6624 - val\_accuracy: 0.6210  
Epoch 19/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6329 - accuracy: 0.6548 - val\_loss: 0.6580 - val\_accuracy: 0.6070  
Epoch 20/100  
80/80 [=====] - 46s 574ms/step - loss: 0.6158 - accuracy: 0.6593 - val\_loss: 0.7263 - val\_accuracy: 0.5780  
Epoch 21/100  
80/80 [=====] - 46s 580ms/step - loss: 0.6024 - accuracy: 0.6821 - val\_loss: 0.6286 - val\_accuracy: 0.6810  
Epoch 22/100  
80/80 [=====] - 46s 573ms/step - loss: 0.6165 - accuracy: 0.6454 - val\_loss: 0.6598 - val\_accuracy: 0.6590  
Epoch 23/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6232 - accuracy: 0.6965 - val\_loss: 0.5968 - val\_accuracy: 0.6880  
Epoch 24/100  
80/80 [=====] - 46s 574ms/step - loss: 0.6133 - accuracy: 0.6736 - val\_loss: 0.6160 - val\_accuracy: 0.6680  
Epoch 25/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6033 - accuracy: 0.6658 - val\_loss: 0.6000 - val\_accuracy: 0.6810  
Epoch 26/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6125 - accuracy: 0.6785 - val\_loss: 0.6253 - val\_accuracy: 0.6520  
Epoch 27/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6615 - accuracy: 0.6739 - val\_loss: 0.6326 - val\_accuracy: 0.6870  
Epoch 28/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5937 - accuracy: 0.6786 - val\_loss: 0.6105 - val\_accuracy: 0.6800  
Epoch 29/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5786 - accuracy: 0.6874 - val\_loss: 0.6581 - val\_accuracy: 0.6380  
Epoch 30/100  
80/80 [=====] - 46s 577ms/step - loss: 0.5994 - accuracy: 0.6855 - val\_loss: 0.6932 - val\_accuracy: 0.6580  
Epoch 31/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5987 - accuracy: 0.6905 - val\_loss: 0.5946 - val\_accuracy: 0.6800  
Epoch 32/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5789 - accuracy: 0.6969 - val\_loss: 0.6360 - val\_accuracy: 0.6250

Epoch 33/100  
80/80 [=====] - 46s 577ms/step - loss: 0.5846 -  
accuracy: 0.6812 - val\_loss: 0.5933 - val\_accuracy: 0.6720  
Epoch 34/100  
80/80 [=====] - 46s 582ms/step - loss: 0.5790 -  
accuracy: 0.7020 - val\_loss: 0.6007 - val\_accuracy: 0.6650  
Epoch 35/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5920 -  
accuracy: 0.6836 - val\_loss: 0.8272 - val\_accuracy: 0.5530  
Epoch 36/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6051 -  
accuracy: 0.6960 - val\_loss: 0.5966 - val\_accuracy: 0.6870  
Epoch 37/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5757 -  
accuracy: 0.7069 - val\_loss: 0.5829 - val\_accuracy: 0.6900  
Epoch 38/100  
80/80 [=====] - 46s 574ms/step - loss: 0.5847 -  
accuracy: 0.7053 - val\_loss: 0.5818 - val\_accuracy: 0.6830  
Epoch 39/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5833 -  
accuracy: 0.7043 - val\_loss: 0.5777 - val\_accuracy: 0.7060  
Epoch 40/100  
80/80 [=====] - 46s 573ms/step - loss: 0.5772 -  
accuracy: 0.6990 - val\_loss: 0.5849 - val\_accuracy: 0.7070  
Epoch 41/100  
80/80 [=====] - 46s 580ms/step - loss: 0.5708 -  
accuracy: 0.7136 - val\_loss: 0.5790 - val\_accuracy: 0.6880  
Epoch 42/100  
80/80 [=====] - 47s 589ms/step - loss: 0.5661 -  
accuracy: 0.7052 - val\_loss: 0.5722 - val\_accuracy: 0.7180  
Epoch 43/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5807 -  
accuracy: 0.7128 - val\_loss: 0.5681 - val\_accuracy: 0.6930  
Epoch 44/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5768 -  
accuracy: 0.6969 - val\_loss: 0.7631 - val\_accuracy: 0.5700  
Epoch 45/100  
80/80 [=====] - 46s 577ms/step - loss: 0.5877 -  
accuracy: 0.6909 - val\_loss: 0.5805 - val\_accuracy: 0.7070  
Epoch 46/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5761 -  
accuracy: 0.6998 - val\_loss: 0.5890 - val\_accuracy: 0.6970  
Epoch 47/100  
80/80 [=====] - 47s 584ms/step - loss: 0.5642 -  
accuracy: 0.7085 - val\_loss: 0.5810 - val\_accuracy: 0.7000  
Epoch 48/100  
80/80 [=====] - 47s 593ms/step - loss: 0.5683 -  
accuracy: 0.6974 - val\_loss: 0.6504 - val\_accuracy: 0.6690



Epoch 49/100  
80/80 [=====] - 48s 602ms/step - loss: 0.5858 - accuracy: 0.6870 - val\_loss: 0.5809 - val\_accuracy: 0.7090  
Epoch 50/100  
80/80 [=====] - 48s 602ms/step - loss: 0.5795 - accuracy: 0.6962 - val\_loss: 0.6041 - val\_accuracy: 0.7060  
Epoch 51/100  
80/80 [=====] - 49s 609ms/step - loss: 0.5806 - accuracy: 0.7147 - val\_loss: 0.6226 - val\_accuracy: 0.6780  
Epoch 52/100  
80/80 [=====] - 49s 615ms/step - loss: 0.5725 - accuracy: 0.7003 - val\_loss: 0.5930 - val\_accuracy: 0.6970  
Epoch 53/100  
80/80 [=====] - 49s 616ms/step - loss: 0.5577 - accuracy: 0.7159 - val\_loss: 0.7138 - val\_accuracy: 0.5860  
Epoch 54/100  
80/80 [=====] - 50s 627ms/step - loss: 0.5827 - accuracy: 0.7091 - val\_loss: 0.7646 - val\_accuracy: 0.6060  
Epoch 55/100  
80/80 [=====] - 50s 622ms/step - loss: 0.5773 - accuracy: 0.7033 - val\_loss: 0.5700 - val\_accuracy: 0.7100  
Epoch 56/100  
80/80 [=====] - 50s 627ms/step - loss: 0.5567 - accuracy: 0.7228 - val\_loss: 0.5790 - val\_accuracy: 0.6810  
Epoch 57/100  
80/80 [=====] - 50s 624ms/step - loss: 0.5813 - accuracy: 0.7011 - val\_loss: 0.5698 - val\_accuracy: 0.6940  
Epoch 58/100  
80/80 [=====] - 50s 624ms/step - loss: 0.5895 - accuracy: 0.7013 - val\_loss: 0.5771 - val\_accuracy: 0.6960  
Epoch 59/100  
80/80 [=====] - 50s 629ms/step - loss: 0.5749 - accuracy: 0.7025 - val\_loss: 0.6038 - val\_accuracy: 0.6710  
Epoch 60/100  
80/80 [=====] - 50s 633ms/step - loss: 0.5568 - accuracy: 0.7191 - val\_loss: 0.5785 - val\_accuracy: 0.7190  
Epoch 61/100  
80/80 [=====] - 50s 626ms/step - loss: 0.5686 - accuracy: 0.7074 - val\_loss: 0.6030 - val\_accuracy: 0.6830  
Epoch 62/100  
80/80 [=====] - 50s 630ms/step - loss: 0.5587 - accuracy: 0.7199 - val\_loss: 0.6478 - val\_accuracy: 0.6500  
Epoch 63/100  
80/80 [=====] - 50s 630ms/step - loss: 0.5843 - accuracy: 0.7016 - val\_loss: 0.5635 - val\_accuracy: 0.7100  
Epoch 64/100  
80/80 [=====] - 51s 636ms/step - loss: 0.5606 - accuracy: 0.7049 - val\_loss: 0.5621 - val\_accuracy: 0.7120

Epoch 65/100  
80/80 [=====] - 50s 631ms/step - loss: 0.5583 -  
accuracy: 0.7001 - val\_loss: 0.5682 - val\_accuracy: 0.7060  
Epoch 66/100  
80/80 [=====] - 51s 636ms/step - loss: 0.5689 -  
accuracy: 0.6921 - val\_loss: 0.5637 - val\_accuracy: 0.7110  
Epoch 67/100  
80/80 [=====] - 51s 638ms/step - loss: 0.5516 -  
accuracy: 0.7334 - val\_loss: 0.5625 - val\_accuracy: 0.7130  
Epoch 68/100  
80/80 [=====] - 51s 640ms/step - loss: 0.5647 -  
accuracy: 0.7244 - val\_loss: 0.5459 - val\_accuracy: 0.7320  
Epoch 69/100  
80/80 [=====] - 51s 639ms/step - loss: 0.5507 -  
accuracy: 0.6967 - val\_loss: 0.5361 - val\_accuracy: 0.7370  
Epoch 70/100  
80/80 [=====] - 51s 638ms/step - loss: 0.5515 -  
accuracy: 0.7184 - val\_loss: 0.5767 - val\_accuracy: 0.6960  
Epoch 71/100  
80/80 [=====] - 50s 631ms/step - loss: 0.5588 -  
accuracy: 0.7203 - val\_loss: 0.5800 - val\_accuracy: 0.7010  
Epoch 72/100  
80/80 [=====] - 49s 613ms/step - loss: 0.5582 -  
accuracy: 0.7131 - val\_loss: 0.5815 - val\_accuracy: 0.7060  
Epoch 73/100  
80/80 [=====] - 50s 622ms/step - loss: 0.5834 -  
accuracy: 0.7244 - val\_loss: 0.5840 - val\_accuracy: 0.6880  
Epoch 74/100  
80/80 [=====] - 50s 622ms/step - loss: 0.5854 -  
accuracy: 0.6884 - val\_loss: 0.5528 - val\_accuracy: 0.7250  
Epoch 75/100  
80/80 [=====] - 50s 623ms/step - loss: 0.5414 -  
accuracy: 0.7393 - val\_loss: 0.5675 - val\_accuracy: 0.7100  
Epoch 76/100  
80/80 [=====] - 50s 630ms/step - loss: 0.5541 -  
accuracy: 0.7194 - val\_loss: 0.5690 - val\_accuracy: 0.7120  
Epoch 77/100  
80/80 [=====] - 51s 637ms/step - loss: 0.5544 -  
accuracy: 0.7109 - val\_loss: 0.5641 - val\_accuracy: 0.7150  
Epoch 78/100  
80/80 [=====] - 51s 637ms/step - loss: 0.5475 -  
accuracy: 0.7435 - val\_loss: 0.5820 - val\_accuracy: 0.6960  
Epoch 79/100  
80/80 [=====] - 51s 641ms/step - loss: 0.5377 -  
accuracy: 0.7314 - val\_loss: 0.5893 - val\_accuracy: 0.6670  
Epoch 80/100  
80/80 [=====] - 51s 639ms/step - loss: 0.5418 -  
accuracy: 0.7443 - val\_loss: 0.5816 - val\_accuracy: 0.7240

Epoch 81/100  
80/80 [=====] - 51s 639ms/step - loss: 0.5353 - accuracy: 0.7301 - val\_loss: 0.8561 - val\_accuracy: 0.6640  
Epoch 82/100  
80/80 [=====] - 50s 622ms/step - loss: 0.5869 - accuracy: 0.7162 - val\_loss: 0.5578 - val\_accuracy: 0.7160  
Epoch 83/100  
80/80 [=====] - 49s 609ms/step - loss: 0.5720 - accuracy: 0.7067 - val\_loss: 0.5620 - val\_accuracy: 0.7220  
Epoch 84/100  
80/80 [=====] - 47s 591ms/step - loss: 0.5410 - accuracy: 0.7362 - val\_loss: 0.6043 - val\_accuracy: 0.7110  
Epoch 85/100  
80/80 [=====] - 47s 594ms/step - loss: 0.5519 - accuracy: 0.7284 - val\_loss: 0.5598 - val\_accuracy: 0.7280  
Epoch 86/100  
80/80 [=====] - 47s 586ms/step - loss: 0.5383 - accuracy: 0.7417 - val\_loss: 0.5821 - val\_accuracy: 0.7160  
Epoch 87/100  
80/80 [=====] - 46s 577ms/step - loss: 0.5436 - accuracy: 0.7276 - val\_loss: 0.5458 - val\_accuracy: 0.7290  
Epoch 88/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5384 - accuracy: 0.7388 - val\_loss: 0.5694 - val\_accuracy: 0.7000  
Epoch 89/100  
80/80 [=====] - 46s 574ms/step - loss: 0.5606 - accuracy: 0.7096 - val\_loss: 0.5786 - val\_accuracy: 0.7300  
Epoch 90/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5501 - accuracy: 0.7191 - val\_loss: 0.5931 - val\_accuracy: 0.6840  
Epoch 91/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5403 - accuracy: 0.7096 - val\_loss: 0.5620 - val\_accuracy: 0.7100  
Epoch 92/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5643 - accuracy: 0.7081 - val\_loss: 0.5706 - val\_accuracy: 0.7020  
Epoch 93/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5531 - accuracy: 0.7105 - val\_loss: 0.6005 - val\_accuracy: 0.7030  
Epoch 94/100  
80/80 [=====] - 46s 573ms/step - loss: 0.5299 - accuracy: 0.7401 - val\_loss: 0.5523 - val\_accuracy: 0.7340  
Epoch 95/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5385 - accuracy: 0.7439 - val\_loss: 0.5754 - val\_accuracy: 0.7100  
Epoch 96/100  
80/80 [=====] - 46s 573ms/step - loss: 0.5509 - accuracy: 0.7305 - val\_loss: 0.5650 - val\_accuracy: 0.7060

```

Epoch 97/100
80/80 [=====] - 46s 575ms/step - loss: 0.6410 -
accuracy: 0.7368 - val_loss: 0.6151 - val_accuracy: 0.6800
Epoch 98/100
80/80 [=====] - 46s 574ms/step - loss: 0.5579 -
accuracy: 0.7273 - val_loss: 0.6079 - val_accuracy: 0.6900
Epoch 99/100
80/80 [=====] - 47s 584ms/step - loss: 0.5487 -
accuracy: 0.7199 - val_loss: 0.5760 - val_accuracy: 0.7180
Epoch 100/100
80/80 [=====] - 46s 575ms/step - loss: 0.8669 -
accuracy: 0.7350 - val_loss: 0.6054 - val_accuracy: 0.6980

```

A continuación se realizan unas gráficas que permiten observar la evolución del *accuracy* y el valor de la función de coste a cada *epoch* del entrenamiento y por cada conjunto de imágenes (entrenamiento y validación).

```

[ ]: epochs = 100

acc = history.history['accuracy']
val_acc = history.history['val_accuracy']


loss = history.history['loss']
val_loss = history.history['val_loss']

epochs_range = range(epochs)

plt.figure(figsize=(8, 8))
plt.subplot(1, 2, 1)
plt.plot(epochs_range, acc, label='Training Accuracy')
plt.plot(epochs_range, val_acc, label='Validation Accuracy')
plt.legend(loc='lower right')
plt.title('Training and Validation Accuracy')

plt.subplot(1, 2, 2)
plt.plot(epochs_range, loss, label='Training Loss')
plt.plot(epochs_range, val_loss, label='Validation Loss')
plt.legend(loc='upper right')
plt.title('Training and Validation Loss')
plt.show()

```



Lo primero a comentar es que el entrenamiento del modelo parece ir bien: a cuantas más *epochs*, menor error en la clasificación. Así que el proceso de aprendizaje está asegurado. Por otro lado, el *accuracy* del entrenamiento y el de validación son similares en cada *epoch*, por lo que no existen indicio de *overfitting*. Si que se observan algunas *epochs* en lo que existe una mayor diferencia entre entrenamiento y validación, pero son casos puntuales y no mayor a 0.2. Por el contrario, un ejemplo de *overfitting* sería aquel en el que el *accuracy* del entrenamiento crece a medida que se hacen más *epochs*, mientras que el de la validación se mantiene casi constante a partir de un cierto punto. Esto indicaría un aprendizaje demasiado exacto del conjunto de entrenamiento y, por lo tanto, mala generalización a nuevas observaciones.

En la segunda gráfica se contempla como el error a partir de la primera *epoch* desciende a valores muy cercano a 0 en el conjunto de entrenamiento. Dicho descenso no ocurre en la validación ya que en el momento de evaluar la función de coste con este grupo, los pesos ya estan actualizados y, por lo tanto, se producen mejores resultados que al principio con una inicialización aleatoria de los pesos.

**Modelo 2** En este segundo modelo se toma como función de activación de la última capa la función sigmoide. Esta función dará la probabilidad de que una imagen pertenezca a la clase 1 (perros, en este caso). Por lo tanto, en la última capa solo se dispondrá de 1 neurona, a diferencia de las dos neuronas del modelo 1 que ofrecían las probabilidades de que una imagen fuese perro o gato, cuya suma era igual a 1. Si se pusiesen dos neuronas con una función de activación sigmoideal, darían dos probabilidades independientes, lo cual resulta difícil de interpretar y posiblemente no sea correcto para el entrenamiento de la red.

La arquitectura de esta red es idéntica a la del modelo 1 con tal de poder establecer una comparación válida posteriormente.

```
[ ]: model_2 = Sequential([
    layers.InputLayer(input_shape=(img_height,img_width,3)),
    layers.Conv2D(10, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Conv2D(20, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Conv2D(40, 3, padding='same', activation='relu'),
    layers.MaxPooling2D(),
    layers.Flatten(),
    layers.Dense(128, activation='relu'),
    layers.Dense(1,activation='sigmoid')
])
```

En este caso, al no disponerse de dos o más salidas en forma de distribución de probabilidad, la función de coste *sparse categorical cross entropy* no es adecuada para el entrenamiento. Por ese motivo se hace uso de *binary cross entropy*.

Tanto la métrica como el método de optimización se mantienen iguales al modelo 1.

```
[ ]: model_2.compile(loss=tf.keras.losses.BinaryCrossentropy(),
    metrics=['accuracy'])
```

```
[ ]: model_2.summary()
```

Model: "sequential\_11"

Layer (type)	Output Shape	Param #
=====		
conv2d_33 (Conv2D)	(None, 256, 256, 10)	280
-----		
max_pooling2d_33 (MaxPooling)	(None, 128, 128, 10)	0
-----		
conv2d_34 (Conv2D)	(None, 128, 128, 20)	1820
-----		
max_pooling2d_34 (MaxPooling)	(None, 64, 64, 20)	0
-----		
conv2d_35 (Conv2D)	(None, 64, 64, 40)	7240
-----		

```

max_pooling2d_35 (MaxPooling (None, 32, 32, 40)          0
-----
flatten_11 (Flatten)          (None, 40960)          0
-----
dense_22 (Dense)              (None, 128)          5243008
-----
dense_23 (Dense)              (None, 1)           129
=====
Total params: 5,252,477
Trainable params: 5,252,477
Non-trainable params: 0
-----

```

Se entrena el modelo con las mismas *epochs* y *steps\_per\_epoch*.

```
[ ]: history_2 = model_2.fit_generator (
    train_generator,
    steps_per_epoch = 2000/batch_size,
    epochs = 100,
    validation_data = validation_generator,
    validation_steps=1000/batch_size
)
```

```

/usr/local/lib/python3.6/dist-
packages/tensorflow/python/keras/engine/training.py:1844: UserWarning:
`Model.fit_generator` is deprecated and will be removed in a future version.
Please use `Model.fit`, which supports generators.
  warnings.warn("`Model.fit_generator` is deprecated and '
/usr/local/lib/python3.6/dist-
packages/keras_preprocessing/image/image_data_generator.py:720: UserWarning:
This ImageDataGenerator specifies `featurewise_center`, but it hasn't been fit
on any training data. Fit it first by calling `.fit(numpy_data)`.
  warnings.warn('This ImageDataGenerator specifies '
/usr/local/lib/python3.6/dist-
packages/keras_preprocessing/image/image_data_generator.py:728: UserWarning:
This ImageDataGenerator specifies `featurewise_std_normalization`, but it hasn't
been fit on any training data. Fit it first by calling `.fit(numpy_data)`.
  warnings.warn('This ImageDataGenerator specifies '

```

```

Epoch 1/100
80/80 [=====] - 47s 582ms/step - loss: 452.0248 -
accuracy: 0.4988 - val_loss: 0.7108 - val_accuracy: 0.5210
Epoch 2/100
80/80 [=====] - 46s 582ms/step - loss: 0.7463 -
accuracy: 0.5034 - val_loss: 0.8171 - val_accuracy: 0.5020
Epoch 3/100
80/80 [=====] - 46s 576ms/step - loss: 1.0355 -
accuracy: 0.5462 - val_loss: 0.6808 - val_accuracy: 0.5650
Epoch 4/100

```

80/80 [=====] - 46s 576ms/step - loss: 0.7667 -  
accuracy: 0.5448 - val\_loss: 0.6808 - val\_accuracy: 0.5540  
Epoch 5/100  
80/80 [=====] - 46s 574ms/step - loss: 0.7024 -  
accuracy: 0.5571 - val\_loss: 0.6876 - val\_accuracy: 0.5400  
Epoch 6/100  
80/80 [=====] - 46s 576ms/step - loss: 0.7433 -  
accuracy: 0.5567 - val\_loss: 0.6802 - val\_accuracy: 0.5610  
Epoch 7/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6741 -  
accuracy: 0.5571 - val\_loss: 0.7002 - val\_accuracy: 0.5480  
Epoch 8/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6942 -  
accuracy: 0.5685 - val\_loss: 0.7249 - val\_accuracy: 0.5090  
Epoch 9/100  
80/80 [=====] - 47s 585ms/step - loss: 0.7398 -  
accuracy: 0.5342 - val\_loss: 0.8728 - val\_accuracy: 0.5460  
Epoch 10/100  
80/80 [=====] - 46s 578ms/step - loss: 0.7641 -  
accuracy: 0.5597 - val\_loss: 0.6619 - val\_accuracy: 0.5590  
Epoch 11/100  
80/80 [=====] - 46s 578ms/step - loss: 0.6839 -  
accuracy: 0.5726 - val\_loss: 0.7357 - val\_accuracy: 0.5700  
Epoch 12/100  
80/80 [=====] - 46s 577ms/step - loss: 0.8729 -  
accuracy: 0.5449 - val\_loss: 0.6780 - val\_accuracy: 0.5630  
Epoch 13/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6907 -  
accuracy: 0.5227 - val\_loss: 0.7029 - val\_accuracy: 0.5250  
Epoch 14/100  
80/80 [=====] - 46s 576ms/step - loss: 0.7181 -  
accuracy: 0.5830 - val\_loss: 0.8179 - val\_accuracy: 0.5150  
Epoch 15/100  
80/80 [=====] - 46s 579ms/step - loss: 0.7022 -  
accuracy: 0.5391 - val\_loss: 0.6688 - val\_accuracy: 0.5700  
Epoch 16/100  
80/80 [=====] - 47s 584ms/step - loss: 0.8244 -  
accuracy: 0.5972 - val\_loss: 0.6686 - val\_accuracy: 0.5770  
Epoch 17/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6778 -  
accuracy: 0.5787 - val\_loss: 0.6795 - val\_accuracy: 0.5490  
Epoch 18/100  
80/80 [=====] - 46s 577ms/step - loss: 0.7474 -  
accuracy: 0.5942 - val\_loss: 0.8118 - val\_accuracy: 0.5240  
Epoch 19/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6868 -  
accuracy: 0.5732 - val\_loss: 0.6680 - val\_accuracy: 0.6140  
Epoch 20/100



80/80 [=====] - 46s 578ms/step - loss: 0.6585 -  
accuracy: 0.5724 - val\_loss: 0.6474 - val\_accuracy: 0.6270  
Epoch 21/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6627 -  
accuracy: 0.6235 - val\_loss: 0.6879 - val\_accuracy: 0.6340  
Epoch 22/100  
80/80 [=====] - 46s 581ms/step - loss: 0.6764 -  
accuracy: 0.6303 - val\_loss: 0.6826 - val\_accuracy: 0.5950  
Epoch 23/100  
80/80 [=====] - 47s 584ms/step - loss: 0.6367 -  
accuracy: 0.6335 - val\_loss: 0.7181 - val\_accuracy: 0.6050  
Epoch 24/100  
80/80 [=====] - 46s 576ms/step - loss: 0.7197 -  
accuracy: 0.6614 - val\_loss: 0.7663 - val\_accuracy: 0.5350  
Epoch 25/100  
80/80 [=====] - 46s 578ms/step - loss: 0.7473 -  
accuracy: 0.6413 - val\_loss: 0.6329 - val\_accuracy: 0.6670  
Epoch 26/100  
80/80 [=====] - 46s 575ms/step - loss: 0.6240 -  
accuracy: 0.6497 - val\_loss: 0.6801 - val\_accuracy: 0.6380  
Epoch 27/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6231 -  
accuracy: 0.6791 - val\_loss: 0.6365 - val\_accuracy: 0.6650  
Epoch 28/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6810 -  
accuracy: 0.6810 - val\_loss: 0.6036 - val\_accuracy: 0.6460  
Epoch 29/100  
80/80 [=====] - 47s 584ms/step - loss: 0.6153 -  
accuracy: 0.6801 - val\_loss: 0.6767 - val\_accuracy: 0.6260  
Epoch 30/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6430 -  
accuracy: 0.6542 - val\_loss: 0.6198 - val\_accuracy: 0.6450  
Epoch 31/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6340 -  
accuracy: 0.6557 - val\_loss: 0.6086 - val\_accuracy: 0.6860  
Epoch 32/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6423 -  
accuracy: 0.6708 - val\_loss: 0.6240 - val\_accuracy: 0.6910  
Epoch 33/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6384 -  
accuracy: 0.6578 - val\_loss: 0.6403 - val\_accuracy: 0.6270  
Epoch 34/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6123 -  
accuracy: 0.6597 - val\_loss: 0.6473 - val\_accuracy: 0.6630  
Epoch 35/100  
80/80 [=====] - 46s 578ms/step - loss: 0.6146 -  
accuracy: 0.6690 - val\_loss: 0.5867 - val\_accuracy: 0.6940  
Epoch 36/100

80/80 [=====] - 47s 584ms/step - loss: 0.6277 -  
accuracy: 0.6727 - val\_loss: 0.6104 - val\_accuracy: 0.6540  
Epoch 37/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6059 -  
accuracy: 0.6861 - val\_loss: 0.6070 - val\_accuracy: 0.6780  
Epoch 38/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6016 -  
accuracy: 0.6702 - val\_loss: 0.6375 - val\_accuracy: 0.6550  
Epoch 39/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6231 -  
accuracy: 0.6705 - val\_loss: 0.6469 - val\_accuracy: 0.6630  
Epoch 40/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5935 -  
accuracy: 0.7000 - val\_loss: 0.5721 - val\_accuracy: 0.7050  
Epoch 41/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5956 -  
accuracy: 0.6752 - val\_loss: 0.6351 - val\_accuracy: 0.6400  
Epoch 42/100  
80/80 [=====] - 46s 581ms/step - loss: 0.6170 -  
accuracy: 0.6821 - val\_loss: 0.6068 - val\_accuracy: 0.6860  
Epoch 43/100  
80/80 [=====] - 47s 584ms/step - loss: 0.5913 -  
accuracy: 0.6766 - val\_loss: 0.6088 - val\_accuracy: 0.6680  
Epoch 44/100  
80/80 [=====] - 46s 580ms/step - loss: 0.6070 -  
accuracy: 0.6952 - val\_loss: 0.6268 - val\_accuracy: 0.6710  
Epoch 45/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5982 -  
accuracy: 0.6850 - val\_loss: 0.5902 - val\_accuracy: 0.6760  
Epoch 46/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6474 -  
accuracy: 0.7020 - val\_loss: 0.5839 - val\_accuracy: 0.6860  
Epoch 47/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6383 -  
accuracy: 0.6654 - val\_loss: 0.5970 - val\_accuracy: 0.6880  
Epoch 48/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5794 -  
accuracy: 0.7069 - val\_loss: 0.5976 - val\_accuracy: 0.6970  
Epoch 49/100  
80/80 [=====] - 46s 577ms/step - loss: 0.7776 -  
accuracy: 0.7212 - val\_loss: 0.5713 - val\_accuracy: 0.7200  
Epoch 50/100  
80/80 [=====] - 47s 584ms/step - loss: 0.5963 -  
accuracy: 0.6937 - val\_loss: 0.6139 - val\_accuracy: 0.6950  
Epoch 51/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5979 -  
accuracy: 0.6965 - val\_loss: 0.6193 - val\_accuracy: 0.6730  
Epoch 52/100

80/80 [=====] - 46s 576ms/step - loss: 0.5890 -  
accuracy: 0.6988 - val\_loss: 0.6376 - val\_accuracy: 0.6670  
Epoch 53/100  
80/80 [=====] - 46s 577ms/step - loss: 0.6156 -  
accuracy: 0.7211 - val\_loss: 0.6148 - val\_accuracy: 0.6590  
Epoch 54/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5837 -  
accuracy: 0.7015 - val\_loss: 0.6119 - val\_accuracy: 0.6930  
Epoch 55/100  
80/80 [=====] - 46s 580ms/step - loss: 0.5823 -  
accuracy: 0.7048 - val\_loss: 0.5890 - val\_accuracy: 0.6930  
Epoch 56/100  
80/80 [=====] - 46s 582ms/step - loss: 0.5701 -  
accuracy: 0.7038 - val\_loss: 0.7542 - val\_accuracy: 0.6890  
Epoch 57/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5929 -  
accuracy: 0.6976 - val\_loss: 0.5952 - val\_accuracy: 0.6900  
Epoch 58/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5787 -  
accuracy: 0.7098 - val\_loss: 0.5802 - val\_accuracy: 0.6880  
Epoch 59/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5567 -  
accuracy: 0.7058 - val\_loss: 0.6547 - val\_accuracy: 0.7080  
Epoch 60/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5995 -  
accuracy: 0.6856 - val\_loss: 0.6567 - val\_accuracy: 0.6450  
Epoch 61/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5926 -  
accuracy: 0.6983 - val\_loss: 0.5867 - val\_accuracy: 0.6880  
Epoch 62/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5931 -  
accuracy: 0.6831 - val\_loss: 0.5988 - val\_accuracy: 0.7070  
Epoch 63/100  
80/80 [=====] - 46s 582ms/step - loss: 0.5699 -  
accuracy: 0.7119 - val\_loss: 0.6355 - val\_accuracy: 0.7160  
Epoch 64/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5919 -  
accuracy: 0.6969 - val\_loss: 0.5924 - val\_accuracy: 0.7040  
Epoch 65/100  
80/80 [=====] - 46s 579ms/step - loss: 0.6099 -  
accuracy: 0.7098 - val\_loss: 0.6838 - val\_accuracy: 0.6970  
Epoch 66/100  
80/80 [=====] - 46s 575ms/step - loss: 0.5727 -  
accuracy: 0.7151 - val\_loss: 0.6089 - val\_accuracy: 0.7150  
Epoch 67/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5716 -  
accuracy: 0.7150 - val\_loss: 0.6239 - val\_accuracy: 0.6930  
Epoch 68/100

80/80 [=====] - 46s 578ms/step - loss: 0.5974 -  
accuracy: 0.6915 - val\_loss: 0.5962 - val\_accuracy: 0.6650  
Epoch 69/100  
80/80 [=====] - 47s 585ms/step - loss: 0.5633 -  
accuracy: 0.6954 - val\_loss: 0.7219 - val\_accuracy: 0.6390  
Epoch 70/100  
80/80 [=====] - 49s 612ms/step - loss: 0.5751 -  
accuracy: 0.6970 - val\_loss: 0.5911 - val\_accuracy: 0.6960  
Epoch 71/100  
80/80 [=====] - 46s 583ms/step - loss: 0.5727 -  
accuracy: 0.6985 - val\_loss: 0.5928 - val\_accuracy: 0.7000  
Epoch 72/100  
80/80 [=====] - 47s 584ms/step - loss: 0.5764 -  
accuracy: 0.7008 - val\_loss: 0.7621 - val\_accuracy: 0.6680  
Epoch 73/100  
80/80 [=====] - 46s 582ms/step - loss: 0.5726 -  
accuracy: 0.7260 - val\_loss: 0.6485 - val\_accuracy: 0.7140  
Epoch 74/100  
80/80 [=====] - 47s 585ms/step - loss: 0.5597 -  
accuracy: 0.7253 - val\_loss: 0.5914 - val\_accuracy: 0.7040  
Epoch 75/100  
80/80 [=====] - 47s 584ms/step - loss: 0.5683 -  
accuracy: 0.7255 - val\_loss: 0.7264 - val\_accuracy: 0.6910  
Epoch 76/100  
80/80 [=====] - 47s 586ms/step - loss: 0.5532 -  
accuracy: 0.7312 - val\_loss: 0.6369 - val\_accuracy: 0.6690  
Epoch 77/100  
80/80 [=====] - 47s 585ms/step - loss: 0.5970 -  
accuracy: 0.7082 - val\_loss: 0.7573 - val\_accuracy: 0.6370  
Epoch 78/100  
80/80 [=====] - 46s 580ms/step - loss: 0.7131 -  
accuracy: 0.6977 - val\_loss: 0.5726 - val\_accuracy: 0.7000  
Epoch 79/100  
80/80 [=====] - 46s 580ms/step - loss: 0.5970 -  
accuracy: 0.6941 - val\_loss: 0.6310 - val\_accuracy: 0.6620  
Epoch 80/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5678 -  
accuracy: 0.7114 - val\_loss: 0.6888 - val\_accuracy: 0.6500  
Epoch 81/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5534 -  
accuracy: 0.7194 - val\_loss: 0.7622 - val\_accuracy: 0.6970  
Epoch 82/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5895 -  
accuracy: 0.6883 - val\_loss: 0.7205 - val\_accuracy: 0.6590  
Epoch 83/100  
80/80 [=====] - 47s 587ms/step - loss: 0.5859 -  
accuracy: 0.7160 - val\_loss: 0.5703 - val\_accuracy: 0.7180  
Epoch 84/100

80/80 [=====] - 46s 580ms/step - loss: 0.5481 - accuracy: 0.7123 - val\_loss: 0.5995 - val\_accuracy: 0.6790  
Epoch 85/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5698 - accuracy: 0.7143 - val\_loss: 0.5758 - val\_accuracy: 0.7060  
Epoch 86/100  
80/80 [=====] - 46s 583ms/step - loss: 0.5575 - accuracy: 0.7228 - val\_loss: 0.6731 - val\_accuracy: 0.7120  
Epoch 87/100  
80/80 [=====] - 46s 576ms/step - loss: 0.6075 - accuracy: 0.7004 - val\_loss: 0.8407 - val\_accuracy: 0.7060  
Epoch 88/100  
80/80 [=====] - 46s 580ms/step - loss: 0.6004 - accuracy: 0.7109 - val\_loss: 0.6691 - val\_accuracy: 0.6690  
Epoch 89/100  
80/80 [=====] - 46s 572ms/step - loss: 0.6071 - accuracy: 0.6968 - val\_loss: 0.5620 - val\_accuracy: 0.7140  
Epoch 90/100  
80/80 [=====] - 47s 592ms/step - loss: 0.5793 - accuracy: 0.7002 - val\_loss: 0.5858 - val\_accuracy: 0.6990  
Epoch 91/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5463 - accuracy: 0.7186 - val\_loss: 0.5794 - val\_accuracy: 0.7100  
Epoch 92/100  
80/80 [=====] - 46s 574ms/step - loss: 0.5758 - accuracy: 0.7072 - val\_loss: 0.6430 - val\_accuracy: 0.6320  
Epoch 93/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5308 - accuracy: 0.7401 - val\_loss: 0.5824 - val\_accuracy: 0.7100  
Epoch 94/100  
80/80 [=====] - 46s 578ms/step - loss: 0.5627 - accuracy: 0.7169 - val\_loss: 0.5900 - val\_accuracy: 0.7120  
Epoch 95/100  
80/80 [=====] - 46s 580ms/step - loss: 0.6008 - accuracy: 0.7214 - val\_loss: 0.6248 - val\_accuracy: 0.6970  
Epoch 96/100  
80/80 [=====] - 46s 578ms/step - loss: 0.6017 - accuracy: 0.6988 - val\_loss: 0.5917 - val\_accuracy: 0.7090  
Epoch 97/100  
80/80 [=====] - 46s 581ms/step - loss: 0.5571 - accuracy: 0.7367 - val\_loss: 0.5872 - val\_accuracy: 0.7090  
Epoch 98/100  
80/80 [=====] - 46s 579ms/step - loss: 0.5807 - accuracy: 0.7199 - val\_loss: 0.6039 - val\_accuracy: 0.7140  
Epoch 99/100  
80/80 [=====] - 46s 576ms/step - loss: 0.5669 - accuracy: 0.7160 - val\_loss: 0.6230 - val\_accuracy: 0.6990  
Epoch 100/100

80/80 [=====] - 46s 577ms/step - loss: 0.5577 - accuracy: 0.7329 - val\_loss: 0.5716 - val\_accuracy: 0.7060

Se realizan las mismas gráficas de los valores del *accuracy* y la función de coste.

```
[ ]: epochs_2 = 100

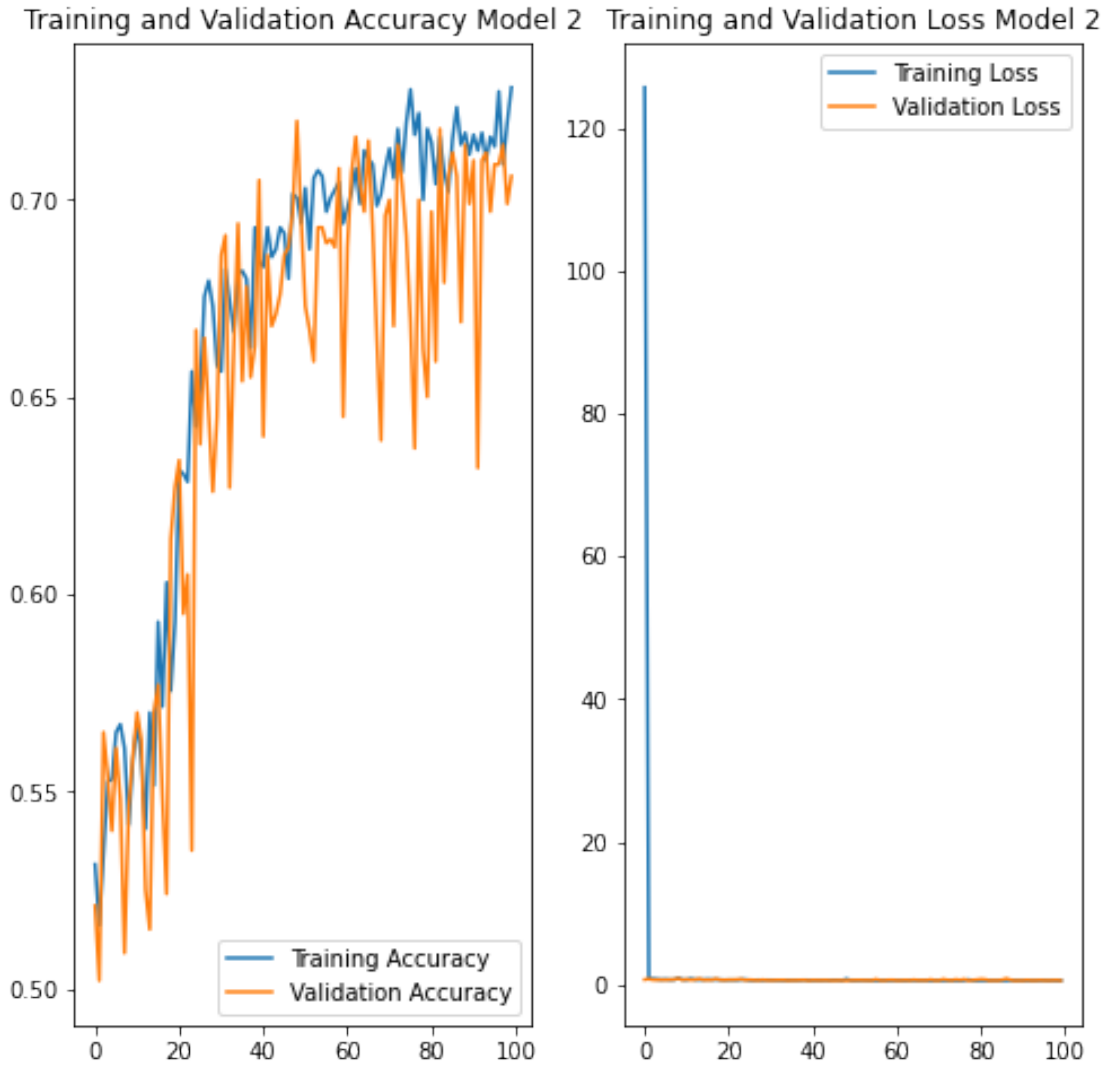
acc_2 = history_2.history['accuracy']
val_acc_2 = history_2.history['val_accuracy']

loss_2 = history_2.history['loss']
val_loss_2 = history_2.history['val_loss']

epochs_range_2 = range(epochs_2)

plt.figure(figsize=(8, 8))
plt.subplot(1, 2, 1)
plt.plot(epochs_range_2, acc_2, label='Training Accuracy')
plt.plot(epochs_range_2, val_acc_2, label='Validation Accuracy')
plt.legend(loc='lower right')
plt.title('Training and Validation Accuracy Model 2')

plt.subplot(1, 2, 2)
plt.plot(epochs_range_2, loss_2, label='Training Loss')
plt.plot(epochs_range_2, val_loss_2, label='Validation Loss')
plt.legend(loc='upper right')
plt.title('Training and Validation Loss Model 2')
plt.show()
```



A simple vista cuesta decidir que modelo funciona mejor observando las gráficas de ambos modelos.

En cuanto al *accuracy*, este modelo 2 parece mantener una mayor armonía en los valores de entrenamiento y validación, no aparecen diferencias puntuales que destaquen a diferencia de lo que pasaba en el modelo 1.


Por otro lado el valor del error, con las gráficas disponibles, parece bastante similar. No obstante, si se observan los valores numéricos que se ofrecen por la salida estándar durante el entrenamiento, se comprueba que el modelo 1 llega a valores un poco más bajos (en torno al 0.55-0.6) que el modelo 2 (en torno el 0.6-0.65).

A continuación se plantean una serie de gráficas que ayudan a realizar una mejor comparación y selección del mejor modelo.

```
[ ]: epochs = 100
epoch_range = range(epochs)

plt.figure(figsize=(8, 8))
plt.subplot(1, 2, 1)
plt.plot(epoch_range, acc, label='Model 1')
plt.plot(epoch_range, acc_2, label='Model 2')
plt.legend(loc='lower right')
plt.title('Training Accuracy Comparison')

plt.subplot(1, 2, 2)
plt.plot(epoch_range, val_acc, label='Model 1')
plt.plot(epoch_range, val_acc_2, label='Model 2')
plt.legend(loc='lower right')
plt.title('Validation Accuracy Comparison')
plt.show()
```





Como puede apreciarse, si solo se fija el punto de mira en el grupo de entrenamiento el modelo 1 obtiene mejor *accuracy* que el modelo 2 en todo momento, especialmente al principio del entrenamiento. Sin embargo este *accuracy* no es tan relevante como el de validación, donde si que queda expuesta la capacidad de generalización del modelo. En este segundo *accuracy*, ambos modelos presentan un progreso parecido. Sin embargo, si tuviese que elegir uno, sería el modelo 1, el cual se impone al modelo 2 tanto al principio como al final del modelo en términos de *accuracy*, a pesar de presentar algunos valles puntuales (ya se ha comentado que no son de gran importancia).

Finalmente se realizan unas gráficas del valor de la función de coste que permitan observar con mayor claridad los valores adquiridos por ambos modelos durante el entrenamiento.

```
[ ]: plt.figure(figsize=(8,8))
plt.subplot(1,2,1)
plt.plot(epoch_range, loss, label = 'Model 1')
plt.plot(epoch_range, loss_2, label = 'Model 2')
plt.ylim([0,1])
plt.legend(loc='upper right')
plt.title('Training Loss Values Comparison')

plt.subplot(1,2,2)
plt.plot(epoch_range, val_loss, label = 'Model 1')
plt.plot(epoch_range, val_loss_2, label = 'Model 2')
plt.ylim([0,1])
plt.legend(loc='upper right')
plt.title('Validation Loss Values Comparison')
```

```
[ ]: Text(0.5, 1.0, 'Validation Loss Values Comparison')
```



De nuevo, en cuanto al conjunto de entrenamiento, el modelo 1 parece tener en todo momento un valor de la función de coste menor al modelo 2. En cuanto al conjunto de validación, esto parece ser cierto también, aunque de una forma menos explícita. Son aspectos que también se han observado en las gráficas del accuracy, pero como es lógico, esta similitud tenía que existir.

Sin embargo, esta comparación de funciones de coste puede no ser válida ya que las funciones de coste son distintas, y por lo tanto el error puede estar en escalas distintas. Ambas funciones deben tener sus mínimos en 0, ya que sino sería imposible de partida obtener un error 0, y por lo tanto una clasificación perfecta (aunque eso suena idealista), pero para una misma diferencia entre la salida deseada y la obtenida, el error puede ser distinto depende de la función usada.